UNEMI
UNIVERSIDAD ESTATAL DE MILAGRO

UNIVERSIDAD ESTATAL DE MILAGRO
FACULTAD DE CIENCIAS E INGENIERÍAS

CARRERA DE INGENIERÍA EN TECNOLOGÍAS DE LA INFORMACIÓN

ESTUDIO DE CASO PREVIO A LA OBTENCIÓN DEL TÍTULO DE: INGENIERO EN TECNOLOGÍAS DE LA INFORMACIÓN

Facultad: Ciencias e Ingenierías

Carrera: Ingeniería en Tecnologías de la Información

Estudiante(s): Marlon David Pérez Almachi
Victor Manuel Lluilema Pisco

Tutor: Msc. Peralta Correa Mirella Azucena
Msc. Espinoza Bravo Maria Gabriela

Milagro, septiembre de 2026

Presidencia de la República del Ecuador

Plan Nacional de Ciencia, Tecnología, Innovación y Saberes

SENESCYT
Secretaría Nacional de Educación Superior, Ciencia, Tecnología e Innovación

REPOSITORIO NACIONAL EN CIENCIA Y TECNOLOGÍA

FICHA DE REGISTRO DE TRABAJO DE GRADUACIÓN

TÍTULO:	Ingeniero en tecnologías de la información
AUTOR(ES) (apellidos/nombres):	Marlon David Pérez Almachi Victor Manuel Lluilema Pisco
REVISOR(ES)/TUTOR(ES) (apellidos/nombres):	M.sc. Peralta Correa Mirella Azucena M.sc. Espinoza Bravo Maria Gabriela
INSTITUCIÓN:	Universidad Estatal de Milagro UNEMI
UNIDAD/FACULTAD:	Ciencias e Ingenierías
CARRERA:	Ingeniería en Tecnologías de la información
GRADO OBTENIDO:	3er nivel
FECHA DE PUBLICACIÓN:	**No. DE PÁGINAS:**
ÁREAS TEMÁTICAS:	Desarrollo de Aplicaciones Web, Ingeniería de Software, Bases de Datos
PALABRAS CLAVES/ KEYWORDS:	Procesamiento de lenguaje natural, aprendizaje automático, inteligencia de negocios, predicción de abandono estudiantil, dashboards interactivos / Natural language processing, machine Learning, business intelligence, student dropout prediction, interactive dashboards.

RESUMEN/ABSTRACT (150-250 palabras):

Se desarrolló un prototipo de sistema de inteligencia de negocios con un modelo predictivo de abandono estudiantil, orientado a que instituciones de educación superior identifiquen tempranamente a los estudiantes en riesgo. La metodología siguió las fases de CRISP-DM: se construyó un almacén de datos (esquema estrella de Kimball) a partir de la trayectoria histórica de 14.508 alumnos, sobre el cual se entrenó un modelo Random Forest validado mediante un esquema temporal; adicionalmente, se aplicó K-Means para segmentar las carreras por riesgo y se integró un motor conversacional de lenguaje natural a SQL (NL2SQL) para consultarlos sin conocimientos técnicos. Los resultados mostraron un ROC-AUC de 0,9999 en la validación temporal y una segmentación de 18 carreras en tres niveles de riesgo, expuestos mediante un panel visual y una interfaz conversacional, ambos sobre la misma fuente de datos, con aislamiento de acceso por institución a nivel del motor de base de datos.

A business intelligence prototype featuring a predictive student dropout model was developed to enable higher education institutions to identify at-risk students early. The methodology followed the CRISP-DM phases: a data warehouse (Kimball star schema) was

<table>
<tr><td colspan="3">built from the historical trajectory of 14,508 students, on which a Random Forest model was trained and validated using a temporal scheme; additionally, K-Means was applied to segment academic programs by risk, and a natural-language-to-SQL (NL2SQL) conversational engine was integrated to query them without technical expertise. Results showed a ROC-AUC of 0.9999 on the temporal validation and a segmentation of 18 academic programs into three risk tiers, exposed through a visual dashboard and a conversational interface, both over the same data source, with institution-level access isolation enforced at the database-engine level.</td></tr>
<tr><td>ADJUNTO PDF:</td><td>SI</td><td>NO</td></tr>
<tr><td>CONTACTO CON AUTOR/ES:</td><td>Teléfono: +593 98 602 3149
Teléfono: +593 98 597 6227</td><td>E-mail: malmachi@unemi.edu.ec
E-mail: vlluilemap@unemi.edu.ec</td></tr>
<tr><td rowspan="3">CONTACTO CON LA INSTITUCIÓN:</td><td colspan="2">Nombre:----------</td></tr>
<tr><td colspan="2">Teléfono:---------</td></tr>
<tr><td colspan="2">E-mail:----------</td></tr>
</table>

UNEMI
UNIVERSIDAD ESTATAL DE MILAGRO

CERTIFICADO SISTEMA ANTI-PLAGIO

Habiendo sido nombradas Peralta Correa Mirella Azucena y Espinoza Bravo María Gabriela, docentes tutoras del trabajo de titulación, certificamos que el presente estudio de caso práctico titulado: **"Prototipo de un sistema web para predecir el abandono en estudiantes universitarios mediante aprendizaje automático y consulta conversacional"** desarrollado por los estudiantes Marlon David Pérez Almachi con C.C.: 0942783457 y Víctor Manuel Lluilema Pisco con C.C.: 0927205286, bajo nuestra supervisión como requisito parcial para la obtención del título de Ingeniero en Tecnologías de la Información, ha sido sometido a la evaluación del programa anti-plagio Compilatio. Una vez realizado el análisis correspondiente, el documento registra un 0 % de porcentaje de similitud, cumpliendo a cabalidad con los parámetros y requerimientos establecidos en la normativa institucional vigente.

Msc. Peralta Correa Mirella Azucena
PROFESORA

Msc. Espinoza Bravo María Gabriela
PROFESORA

UNEMI
UNIVERSIDAD ESTATAL DE MILAGRO

CERTIFICADO

Por la presente, hago constar que he leído el estudio de caso práctico presentado por los estudiantes Marlon David Pérez Almachi con C.C.: 0942783457 y Victor Manuel Lluilema Pisco con C.C.: 0927205286, para optar al título de Ingeniero en tecnologías de la información, indicando que ha cumplido con todos los parámetros establecidos en la normativa vigente:

- El estudiante demuestra conocimiento profesional integral.
- El trabajo presenta una propuesta en el área de conocimiento.
- El nivel de argumentación es coherente con el campo de conocimiento.
- El trabajo está alineado a una de las líneas de investigación.

Dando por concluida las tutorías de trabajo de titulación, CERTIFICO, para los fines pertinentes, que él (los) estudiantes están aptos para continuar con el proceso.

Msc. Peralta Correa Mirella Azucena
PROFESORA

Msc. Espinoza Bravo María Gabriela
PROFESORA

DECLARACIÓN DE AUTORÍA

La responsabilidad del contenido de este estudio de caso práctico, me corresponde exclusivamente; y el patrimonio intelectual de la misma a la UNIVERSIDAD ESTATAL DE MILAGRO.

El trabajo ha sido desarrollado de la siguiente forma:

Fecha	**Actividades**	**Detalla adicional de cumplimiento**	**Evidencia de su trabajo**
En este apartado, deberá ir indicando las fechas y actividades del avance, mínimo 5 actividades donde debe haber al menos 4 interacciones con docentes.			Incluir los enlaces de las evidencias.

_____

FIRMA

Peralta Correa Mirella Azucena

_____

FIRMA

Espinoza Bravo María Gabriela

TABLA DE CONTENIDO

RESUMEN 8

ABSTRACT 9

1. Introducción 10

1.1 Descripción 10

1.2 Propósito del caso 14

1.3 Base conceptual 17

2. Referencias 23

6. Anexos 27

7. Anexo de información académica. 27

ÍNDICE DE FIGURAS

Ilustración 1. Flujo de procesamiento de consulta en lenguaje natural (NL2SQL) 20

Ilustración 2. Arquitectura del sistema predictivo y conversacional 23

ÍNDICE DE TABLAS

Tabla 1. Componentes de la arquitectura del sistema 24

ENLACE DEL VIDEO – PRESENTACION DEL PROYECTO:

https://drive.google.com/file/d/18_yiDyvGPhoAgMhu4lMhR_w30cAHkOoj/view?usp=drive_link

ENLACE DE LA CARPETA EN DRIVE:

https://drive.google.com/drive/folders/160VBr2jUmxQRSzlZE0wZAfUaHr4682xn?usp=sharing

RESUMEN

Se desarrolló un prototipo de sistema de inteligencia de negocios con un modelo predictivo de abandono estudiantil, orientado a que instituciones de educación superior identifiquen tempranamente a los estudiantes en riesgo. La metodología siguió las fases de CRISP-DM: se construyó un almacén de datos (esquema estrella de Kimball) a partir de la trayectoria histórica de 14.508 alumnos, sobre el cual se entrenó un modelo Random Forest validado mediante un esquema temporal; adicionalmente, se aplicó K-Means para segmentar las carreras por riesgo y se integró un motor conversacional de lenguaje natural a SQL (NL2SQL) para consultarlos sin conocimientos técnicos. Los resultados mostraron un ROC-AUC de 0,9999 en la validación temporal y una segmentación de 18 carreras en tres niveles de riesgo, expuestos mediante un panel visual y una interfaz conversacional, ambos sobre la misma fuente de datos, con aislamiento de acceso por institución a nivel del motor de base de datos.

Palabras clave: *Procesamiento de lenguaje natural, aprendizaje automático, inteligencia de negocios, predicción de abandono estudiantil, dashboards interactivos.*

ABSTRACT

A business intelligence prototype featuring a predictive student dropout model was developed to enable higher education institutions to identify at-risk students early. The methodology followed the CRISP-DM phases: a data warehouse (Kimball star schema) was built from the historical trajectory of 14,508 students, on which a Random Forest model was trained and validated using a temporal scheme; additionally, K-Means was applied to segment academic programs by risk, and a natural-language-to-SQL (NL2SQL) conversational engine was integrated to query them without technical expertise. Results showed a ROC-AUC of 0.9999 on the temporal validation and a segmentation of 18 academic programs into three risk tiers, exposed through a visual dashboard and a conversational interface, both over the same data source, with institution-level access isolation enforced at the database-engine level.

Keywords: *Natural language processing, machine Learning, business intelligence, student dropout prediction, interactive dashboards.*

1. Introducción

1.1 Descripción

En el contexto de la transformación digital de la educación superior, la gestión eficiente de la información académica se ha consolidado como un factor determinante para la permanencia y el éxito estudiantil; sin embargo, en la mayoría de instituciones de educación superior (IES) persisten prácticas basadas en el registro del estado actual del estudiante, sin una explotación sistemática de su trayectoria histórica, lo que limita significativamente la capacidad de anticipar el abandono antes de que ocurra.

Esta situación genera múltiples problemáticas, entre las que destacan la ausencia de modelos predictivos integrados a los sistemas de gestión académica, la dispersión de los datos institucionales en sistemas aislados (matrícula, asistencia, financiero) y la dependencia de personal técnico especializado para poder consultar esa información, es así que, como consecuencia, la detección de estudiantes en riesgo de abandono ocurre de manera tardía, generalmente cuando el estudiante ya ha dejado de asistir, en lugar de anticiparse mediante el análisis de su comportamiento académico a lo largo del tiempo.

Las implicaciones de esta problemática se evidencian en la imposibilidad de correlacionar variables clave (asistencia, rendimiento, mora) para priorizar intervenciones de retención, en la falta de referentes comparativos que permitan a una institución dimensionar objetivamente la gravedad de su propia tasa de abandono frente a otras IES, y en la pérdida de recursos institucionales invertidos en estudiantes que finalmente abandonan sus estudios sin que mediara ninguna alerta previa. Esta problemática no es exclusiva del contexto ecuatoriano: en el ámbito latinoamericano, Gutierrez-Pachas, Garcia-Zanabria, Cuadros-Vargas, Camara-Chavez y Gomez-Nieto (2023) analizaron una base de datos longitudinal de seis departamentos académicos de una universidad latinoamericana a lo largo de trece años, combinando aprendizaje automático y análisis de supervivencia para determinar no solo quién abandonaría, sino cuándo lo haría; sus hallazgos confirman que el riesgo de abandono varía de forma significativa según la facultad, el género y el grupo socioeconómico del estudiante, lo que respalda la pertinencia de un modelo predictivo capaz de

segmentar el riesgo por unidad académica, en vez de tratar a la institución como un todo homogéneo, precisamente el enfoque adoptado en el presente trabajo.

Dentro del propio Ecuador, esta problemática ya cuenta con evidencia empírica documentada: Núñez-Naranjo (2024) analizó, mediante regresión logística multinivel, los registros de 1.078 estudiantes admitidos y matriculados a lo largo de cinco años en una universidad privada ecuatoriana, de los cuales 484 abandonaron sus estudios, estimando una probabilidad de abandono del 44,90 % asociada a factores personales, familiares, económicos, académicos e institucionales, con un modelo capaz de predecir el comportamiento de dichas variables con un 76,44 % de precisión, lo que confirma que el fenómeno abordado en este trabajo no es una hipótesis, sino una realidad institucional ya medida y cuantificada dentro del país.

Ante tal contexto, y para dar una mejor justificación de la problemática que se enfrenta en la actualidad, se han identificado cinco causas principales con sus respectivos efectos, los cuales orientan y dan la viabilidad para el desarrollo del trabajo de titulación:

Ausencia de historial académico longitudinal estructurado

Causa: Los sistemas de gestión académica registran el estado actual del estudiante (matrícula vigente), sin conservar su trayectoria histórica en una forma explotable para análisis.

Efectos:

- Imposibilidad de detectar tendencias de deterioro antes del abandono.
- Decisiones institucionales reactivas, no preventivas.
- Pérdida de la ventana de oportunidad para la intervención temprana.
- Subutilización de datos que la institución ya posee.

Falta de modelos predictivos de riesgo de abandono

Causa: Ausencia de herramientas de aprendizaje automático integradas a los sistemas académicos institucionales (Duro et al., 2026).

Efectos:

- Identificación tardía de estudiantes en riesgo.
- Intervenciones de bienestar estudiantil no focalizadas.

- Tasas de deserción no anticipadas.
- Pérdida de recursos invertidos en estudiantes que abandonan.

Dispersión y aislamiento de los datos académicos institucionales

Causa: Cada sistema (matrícula, asistencia, financiero) opera de forma independiente, sin una capa de integración dimensional que los consolide. Al respecto, Komljenovic, Sellar y Birch (2024) documentan que esta fragmentación técnica y organizacional es, precisamente, uno de los obstáculos reales que enfrentan las universidades al intentar convertirse en organizaciones basadas en datos.

Efectos:

- Imposibilidad de correlacionar variables (asistencia, mora, rendimiento) en un solo análisis.
- Reportes incompletos o inconsistentes entre áreas.
- Esfuerzo manual duplicado para consolidar información.
- Decisiones fragmentadas entre facultades.

Limitado acceso a herramientas de inteligencia de negocios conversacional

Causa: Los sistemas de reportería tradicionales exigen conocimiento técnico de SQL o de herramientas de BI para explorar los datos (Sequeira, Reis, Alves, & Branco, 2024; Ascoli & Choi, 2025).

Efectos:

- Dependencia de personal técnico especializado para obtener respuestas.
- Baja adopción por parte de autoridades académicas no técnicas.
- Demoras entre la necesidad de una respuesta y su obtención.
- Subutilización de la información disponible.

Ausencia de referentes comparativos (benchmarking) institucionales

Causa: No existen mecanismos que permitan contrastar los indicadores propios de abandono contra referentes externos (otras IES, promedios nacionales); Lepori y Bornmann (2026) documentan que la comparación entre instituciones pares es una práctica emergente pero aún poco extendida en la evaluación institucional de educación superior.

Efectos:

- Dificultad para dimensionar objetivamente la gravedad de la problemática propia.
- Decisiones sin contexto comparativo.
- Falta de argumentos objetivos para justificar la inversión en retención.
- Aislamiento institucional respecto a buenas prácticas del sector.

Dadas las circunstancias, la necesidad del presente proyecto se sustenta en la ausencia de soluciones tecnológicas integradas que permitan predecir, no solo describir, el riesgo de abandono estudiantil de manera oportuna y confiable. Diversos estudios recientes respaldan esta necesidad: modelos basados en ensemble learning como XGBoost han demostrado ser efectivos para anticipar el abandono incluso antes de la matrícula (Carballo-Mendívil, Arellano-González, Ríos-Vázquez, & Lizardi-Duarte, 2025); de forma similar, el análisis de registros de actividad longitudinal permite identificar patrones de deterioro que preceden al abandono (Marcolino et al., 2025). Una revisión reciente de la literatura confirma que los modelos de árboles (Random Forest, Gradient Boosting) siguen siendo dominantes en este dominio por su balance entre desempeño e interpretabilidad frente a modelos de caja negra (Duro, Gomes, Correia, Borges, & Bernardino, 2026), y estudios con grandes volúmenes de datos han alcanzado niveles de precisión cercanos al 100 % identificando el rendimiento académico como el principal predictor (Kok, Ho, Chen, Koh, & Tian, 2024). Estos hallazgos, en conjunto, refuerzan la viabilidad técnica de un enfoque predictivo como el propuesto en este trabajo.

En cuanto a la conveniencia del proyecto, esta radica en que permite anticipar el abandono antes de que ocurra, en lugar de sólo medirlo después de manera estadística. Sirve para que las autoridades académicas (decanos, directores de carrera, bienestar estudiantil) cuenten con una herramienta que priorice objetivamente a qué estudiantes dirigir sus recursos limitados de retención, en vez de actuar de manera generalizada o reactiva.

El proyecto ayudará a resolver los cinco problemas reales:

- Detección tardía de estudiantes en riesgo de abandono.
- Fragmentación de los datos académicos entre sistemas aislados.
- Dependencia de personal técnico para poder consultar la información institucional.
- Falta de comparabilidad objetiva frente a otras instituciones.
- Pérdida de recursos institucionales invertidos en estudiantes que abandonan sin alerta previa.

Los principales beneficiarios serán las autoridades académicas y el personal de bienestar estudiantil, quienes podrán priorizar sus intervenciones de retención; los propios estudiantes en riesgo, al recibir acompañamiento oportuno; el equipo de planificación institucional, al contar con indicadores comparables frente a referentes externos; e indirectamente el Estado ecuatoriano, dado que la educación superior pública es financiada con recursos públicos cuya pérdida por deserción representa una ineficiencia evitable.

1.2 Propósito del caso

El desarrollo del presente caso de estudio tiene como propósito validar cómo la integración de un modelo predictivo de abandono estudiantil en una plataforma de inteligencia de negocios, apoyada en técnicas de aprendizaje automático y procesamiento de lenguaje natural, puede contribuir a que las instituciones de educación superior anticipen el riesgo de abandono y prioricen objetivamente sus recursos de retención. El caso no se limita, por tanto, a la construcción de una solución tecnológica: también evalúa su utilidad como herramienta que permite a una autoridad académica, sin conocimientos técnicos, consultar y confiar en los resultados de dicho modelo.

A partir de este propósito se establecen los objetivos que orientan tanto el diseño como el desarrollo del prototipo, permitiendo evidenciar el impacto de la predicción temprana, la segmentación institucional y la consulta conversacional sobre la toma de decisiones de retención estudiantil. El objetivo general delimita el estudio respondiendo a tres preguntas: qué se realizará (desarrollar un modelo predictivo de abandono estudiantil), cómo se llevará a cabo (integrado a una plataforma de inteligencia de negocios con dashboards interactivos y procesamiento de lenguaje natural) y para qué (para que las

instituciones de educación superior identifiquen tempranamente a los estudiantes en riesgo).

Objetivo general

Desarrollar un modelo predictivo de abandono estudiantil, integrado a una plataforma de inteligencia de negocios con dashboards interactivos y procesamiento de lenguaje natural, que permita a instituciones de educación superior identificar tempranamente a los estudiantes en riesgo.

Objetivos específicos

- Analizar los procesos actuales de seguimiento académico estudiantil, identificando las variables asociadas al riesgo de abandono en el contexto universitario.
- Implementar el modelo predictivo de abandono estudiantil integrado a un prototipo de plataforma de inteligencia de negocios, con visualización mediante dashboards interactivos y consulta en lenguaje natural.
- Evaluar el desempeño del modelo predictivo mediante validación cruzada y validación temporal, contrastando los resultados frente a referentes institucionales externos, con un desempeño mínimo esperado de 0,90 en el área bajo la curva ROC (AUC-ROC).

Alcance de la solución propuesta

En términos del tipo de alcance en tecnologías de la información, el presente trabajo corresponde a un alcance explicativo-experimental: no se limita a describir el fenómeno del abandono estudiantil, sino que desarrolla y valida una solución tecnológica capaz de intervenir sobre dicho fenómeno mediante la predicción temprana.

Alcance técnico. La plataforma incluye cuatro módulos integrados: un almacén de datos dimensional (esquema estrella de Kimball) que consolida la trayectoria histórica del alumnado; un motor de predicción de abandono basado en Random Forest; un módulo de segmentación institucional mediante K-Means; y un motor conversacional de lenguaje natural a SQL (NL2SQL) que traduce preguntas formuladas en español a consultas ejecutadas contra vistas gobernadas. Estos módulos se integran mediante una API REST (FastAPI) y se exponen a través de un panel visual desarrollado en React.

Alcance funcional. El sistema permite calificar el riesgo de abandono de los alumnos activos, visualizar la segmentación de carreras por nivel de riesgo, consultar los resultados en lenguaje natural sin escribir SQL, y comparar la tasa de abandono propia frente a referentes externos. Queda fuera del alcance de este trabajo: el reentrenamiento automático del modelo en tiempo real, pues la calificación se ejecuta por lotes; la integración con sistemas de notificación institucional (correo electrónico o mensajería a los estudiantes en riesgo); y el despliegue productivo sobre datos operativos reales de una institución, ya que el prototipo se valida sobre datos de prueba de una institución ecuatoriana.

Esta delimitación no es arbitraria: convertir a una institución en una organización basada en datos implica obstáculos organizacionales, legales y técnicos que trascienden un único ciclo de desarrollo (Komljenovic, Sellar, & Birch, 2024). Por lo tanto, se prioriza validar la arquitectura técnica sobre una institución piloto antes de extenderla, dejando la incorporación de nuevas instituciones, agregando únicamente un nuevo perfil de mapeo, sin reescribir el motor predictivo, como una extensión ya prevista en el diseño del sistema.

Criterios de éxito. La solución se considerará exitosa si:

- El modelo predictivo alcanza un ROC-AUC igual o superior a 0,90 en la validación temporal;
- La segmentación institucional agrupa a las carreras en al menos tres niveles de riesgo diferenciables;
- El aislamiento de datos por institución se verifica a nivel del motor de base de datos, de modo que la cuenta de solo lectura del motor conversacional no tenga acceso a las tablas operativas; y
- Una autoridad académica sin conocimientos de SQL logra obtener una respuesta correcta a una pregunta formulada en lenguaje natural, sin intervención técnica.

En síntesis, la solución propuesta alcanzará a las autoridades académicas y al personal de bienestar estudiantil de una institución de educación superior ecuatoriana, sobre datos de prueba equivalentes a los de un entorno productivo real. Incluirá predicción de abandono, segmentación institucional, consulta conversacional y benchmarking externo; quedará fuera de su alcance el reentrenamiento en tiempo real, la notificación automática a

estudiantes y el despliegue multi-institucional; y se considerará exitosa si cumple los cuatro criterios señalados anteriormente.

1.3 Base conceptual

El presente trabajo de titulación se fundamenta en un enfoque epistemológico de carácter pragmático-tecnológico, en el cual el conocimiento se construye a partir de la interacción entre la teoría predictiva (aprendizaje automático) y la práctica institucional (gestión académica), orientado a la solución de un problema real y medible: la identificación tardía del riesgo de abandono estudiantil. Desde esta perspectiva, la realidad institucional se concibe como dinámica y susceptible de mejora mediante la incorporación de inteligencia predictiva a los procesos ya existentes de seguimiento académico, sin requerir el reemplazo de dichos procesos. Este supuesto se distingue de un enfoque estrictamente positivista, en el que el fenómeno del abandono se limitaría a describirse mediante estadísticas descriptivas, y también de uno puramente interpretativo, centrado únicamente en la experiencia subjetiva del estudiante, en favor de una postura intermedia en la que el conocimiento generado por el modelo predictivo se valida por su capacidad de intervenir sobre la realidad institucional, no solo de describirla o interpretarla.

La unidad de análisis del presente estudio de caso es la trayectoria académica longitudinal del estudiante universitario (matrícula, rendimiento, asistencia y situación financiera a lo largo de múltiples periodos), no el estudiante en un corte transversal único. Esta distinción es metodológicamente relevante: como demuestran Duro et al. (2026) en su revisión sistemática, los modelos de mayor validez predictiva son precisamente aquellos que explotan datos longitudinales en lugar de una fotografía del estado actual del estudiante. En términos operativos, esto implica que la unidad mínima de observación no es "el alumno" sino "el alumno en un periodo académico determinado", de modo que un mismo estudiante aporta tantos registros de análisis como periodos haya cursado, permitiendo capturar tendencias de deterioro (caídas sucesivas de asistencia o rendimiento) que resultarían invisibles si cada alumno se observará una sola vez.

El trabajo práctico por desarrollar integra cuatro propuestas tecnológicas, cada una respaldada por antecedentes específicos en la literatura:

Modelo predictivo de abandono estudiantil (Random Forest)

Kok et al. (2024), Carballo-Mendívil et al. (2025) y Rabelo y Zárate (2025) coinciden en que los modelos de ensamble ofrecen el mejor balance entre precisión e interpretabilidad frente a modelos de caja negra menos explicables ante una autoridad académica no técnica. En concreto, Kok et al. (2024) reportan una precisión cercana al 100 % sobre un volumen considerable de datos institucionales, identificando el rendimiento académico como el predictor de mayor peso; Carballo-Mendívil et al. (2025) demuestran que es posible generar alertas tempranas usando exclusivamente datos previos a la matrícula, antes de que exista cualquier información académica del estudiante; y Rabelo y Zárate (2025) reportan que su modelo de ensamble (regresión logística, redes neuronales y árbol de decisión) identifica correctamente al 98,1 % de los abandonos reales. A esto se suma que Duro et al. (2026), en su revisión de modelos de aprendizaje automático y profundo para predicción de abandono, documentan que los modelos de árboles mantienen un desempeño competitivo frente a redes neuronales profundas incluso con volúmenes de datos moderados la condición real de este caso de estudio sin requerir la infraestructura de cómputo que exige el aprendizaje profundo.

Clustering institucional (K-Means)

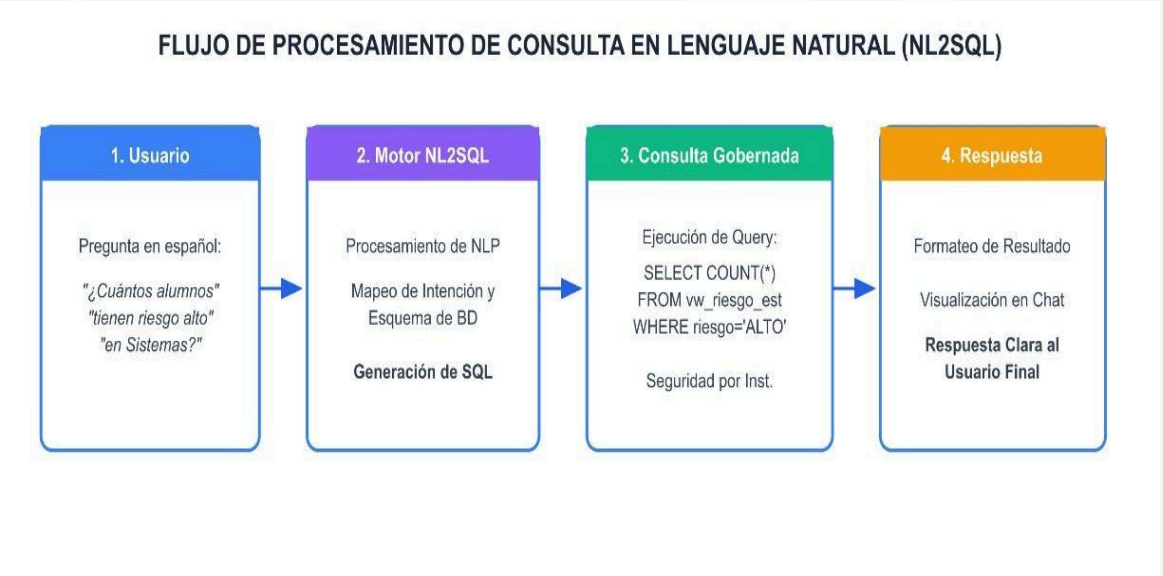
Mohd Talib, Abd Majid y Sahran (2023) validaron el uso de K-Means para identificar patrones de comportamiento estudiantil, agrupando por perfiles de rendimiento en lugar de tratar a la institución como una unidad homogénea, lo que respalda su aplicación para segmentar unidades académicas por perfil de riesgo en el presente caso. Esta segmentación resulta relevante para el caso de estudio porque permite a una autoridad académica priorizar sus recursos de retención por carrera, no solo por alumno individual, identificando qué unidades académicas concentran proporcionalmente más riesgo antes de intervenir de forma generalizada.

Motor conversacional de lenguaje natural a SQL (NL2SQL)

Ascoli y Choi (2025) analizan estrategias de contexto para mejorar la traducción de lenguaje natural a SQL mediante modelos de lenguaje de gran escala, mientras que Sequeira, Reis, Alves y Branco (2024), en su hoja de ruta, identifican la brecha de habilidades técnicas como la principal barrera de adopción de BI en instituciones educativas, orientada a democratizar el acceso

a la información. Ambos antecedentes convergen en un mismo diagnóstico: la tecnología de análisis de datos suele estar disponible, pero su adopción real depende de que la interfaz de consulta no exige conocimiento previo de SQL ni de herramientas de BI especializadas, hallazgo que refuerza, con evidencia cuantitativa, el diagnóstico cualitativo de Komljenovic et al. (2024).

Ilustración 1. *Flujo de procesamiento de consulta en lenguaje natural (NL2SQL)*



Nota. Elaboración propia.

Panel visual (dashboard interactivo)

Orrego Granados, Ugalde, Salas, Torres y López-Gonzales (2022) desarrollaron un enfoque visual-predictivo del rendimiento académico en una universidad peruana, validando la visualización como complemento no como sustituto del modelo predictivo, sobre la misma fuente de datos gobernada que se emplea en este trabajo. En el contexto ecuatoriano específicamente, Mejía-Peñafiel, Aguilar-Reyes, Morocho-Barrionuevo y García-Veloz (2026) documentan una metodología de implementación de dashboards en Power BI para instituciones de educación superior del país, lo que confirma que la infraestructura y la cultura de uso de estas herramientas ya germina localmente; sin embargo, su aplicación se orienta al aprendizaje estadístico de los propios estudiantes, no a la gestión institucional del riesgo de abandono, una diferencia de propósito, no de tecnología, que este trabajo aprovecha.

Komljenovic, Sellar y Birch (2024) documentan, además, desde una posición crítica, las dificultades organizacionales reales que enfrentan las

universidades al intentar convertirse en organizaciones basadas en datos, un antecedente que contextualiza por qué la integración propuesta en este trabajo responde a una necesidad institucional documentada, y no solo a una decisión técnica.

Comparación crítica de trabajos previos

Al contrastar la literatura revisada, se observa que Duro et al. (2026), Carballo-Mendívil et al. (2025), Marcolino et al. (2025), Kok et al. (2024) y Rabelo y Zárate (2025) coinciden en que los modelos de aprendizaje automático superan de forma consistente a los métodos estadísticos tradicionales para la predicción de abandono; sin embargo, desde una posición crítica, se identifica que la totalidad de estos estudios entrena y evalúa el modelo predictivo como un componente aislado, un notebook o script de investigación, sin integrarlo a un sistema de información que un decano o director de carrera pueda consultar directamente. Ninguno de ellos aborda cómo se gobierna el acceso a esa predicción ni cómo se comunica el resultado a un usuario no técnico. En particular, Marcolino et al. (2025) centra su aporte en la optimización del algoritmo de aprendizaje mediante ajuste de hiper parámetros, pero asume que el consumidor final del resultado ya sabe interpretar una matriz de probabilidades, un supuesto que no se sostiene frente a una autoridad académica sin formación técnica.

Por su parte, Sequeira et al. (2024), Mohd Talib et al. (2023) y Lepori y Bornmann (2026) abordan la dimensión de inteligencia de negocios, segmentación y benchmarking institucional respectivamente, esta última mediante un método reproducible para identificar instituciones "pares" comparables por perfil, no por rankings genéricos, pero ninguno los conecta con un modelo predictivo propio: se limitan a la descripción, comparación o visualización de datos históricos, no a la anticipación del riesgo. De manera similar, Ascoli y Choi (2025) resuelven el problema de la interfaz en lenguaje natural, pero sobre bases de datos genéricas, sin el contexto de seguridad multi-institución que exige un entorno académico real.

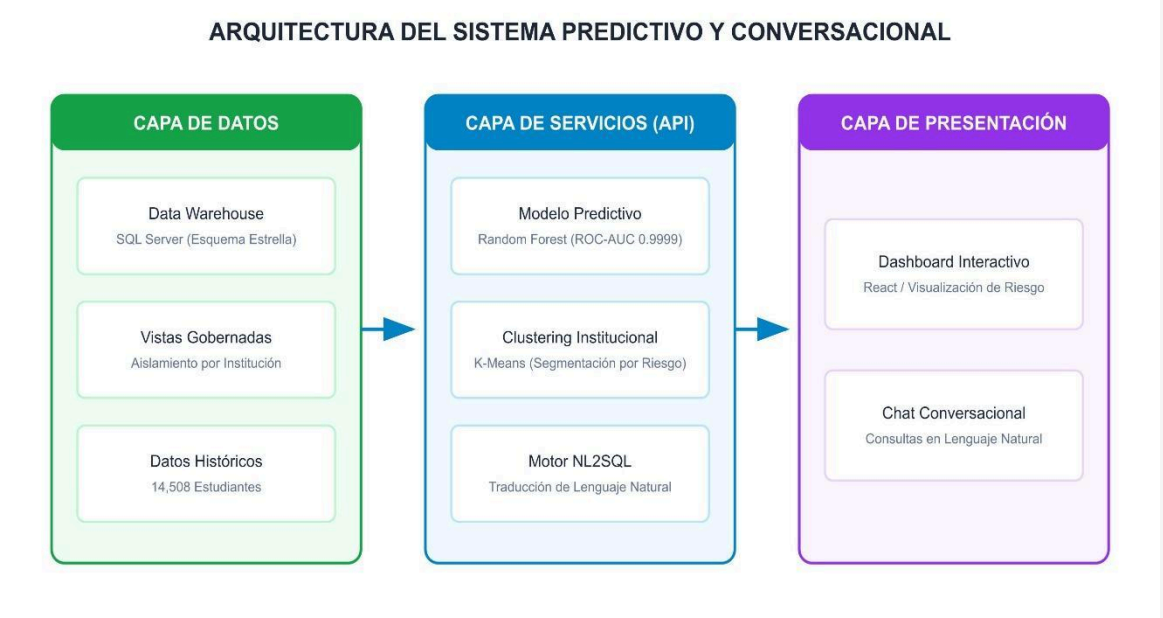
Se concluye, por tanto, que existe un vacío de integración: la literatura resuelve por separado la predicción, la segmentación, la visualización, el benchmarking y la interfaz conversacional, pero ningún estudio revisado las integra bajo una misma arquitectura gobernada. A diferencia de estos enfoques

aislados, el presente trabajo de titulación propone un abordaje integrador: un mismo motor de predicción y de segmentación expuesto simultáneamente mediante un panel visual y una interfaz conversacional NL2SQL, ambos leyendo la misma fuente de datos gobernada, con aislamiento de acceso por institución a nivel del motor de base de datos.

El principal aporte de este estudio radica en demostrar la viabilidad de esa integración sobre datos de prueba de una institución ecuatoriana, sentando una arquitectura reproducible y documentada que podría extenderse a una segunda institución sin reescribir el motor predictivo.

En síntesis, este trabajo aporta la integración, bajo una misma arquitectura gobernada, de tres capacidades que la literatura revisada resuelve por separado: predicción de abandono (Random Forest), segmentación institucional (K-Means) y consulta conversacional en lenguaje natural (NL2SQL), todas leyendo la misma fuente de datos, de modo que el panel visual y el chat nunca muestran cifras distintas, con aislamiento de acceso por institución a nivel del motor de base de datos. De esta integración se derivan beneficios concretos: la detección temprana de estudiantes en riesgo, en vez de tardía; la priorización objetiva de los recursos limitados de retención; el acceso a la información institucional sin necesidad de conocimientos técnicos de SQL; y un referente comparativo externo para dimensionar la propia tasa de abandono frente a otras instituciones. Los principales beneficiarios son, en consecuencia, las autoridades académicas y el personal de bienestar estudiantil, que podrán priorizar sus intervenciones; los propios estudiantes en riesgo, al recibir acompañamiento oportuno; el equipo de planificación institucional; y, de forma indirecta, el Estado ecuatoriano, dado que la pérdida de estudiantes en la educación superior pública representa una ineficiencia evitable.

Ilustración 2. *Arquitectura del sistema predictivo y conversacional*



Nota. Elaboración propia.

Tabla 1. *Componentes de la arquitectura del sistema*

Capa	Componente	Función
Datos	Data warehouse	Consolida el historial académico y financiero en un modelo dimensional único.
Datos	Vistas gobernadas	Aísla el acceso a los datos por institución.
Datos	Datos históricos	14 508 registros para entrenar y validar los modelos.
Servicios	Modelo predictivo	Random Forest: estima la probabilidad de abandono.
Servicios	Clustering	K-Means: agrupa carreras por nivel de riesgo.
Servicios	Motor NL2SQL	Traduce preguntas en español a consultas SQL.
Presentación	Dashboard	Visualiza el riesgo por estudiante y carrera.
Presentación	Chat conversacional	Responde consultas sin necesidad de saber SQL.

Nota. Elaboración propia a partir del diseño técnico del prototipo.

Lo que se prevé cambiar con este trabajo es, en esencia, el paso de una gestión reactiva del abandono, medirlo después de ocurrido, a una gestión

anticipatoria que lo predice antes de que ocurra, así como el paso de una dependencia de personal técnico para consultar los datos institucionales a un acceso conversacional directo para cualquier autoridad académica, sin intermediarios. Su utilidad radica, precisamente, en servir como herramienta de apoyo a la decisión para priorizar a qué estudiantes dirigir los recursos de retención, y como arquitectura de referencia reproducible que puede extenderse a una segunda institución de educación superior agregando únicamente un nuevo perfil de mapeo, sin reescribir el motor predictivo.

En cuanto a si ayudará a resolver algún problema o gama de problemas prácticos, la respuesta es afirmativa: atiende los cinco problemas identificados en la sección 1.1, a saber, la detección tardía de estudiantes en riesgo, la fragmentación de los datos académicos entre sistemas aislados, la dependencia de personal técnico para consultar la información, la falta de comparabilidad frente a otras instituciones, y la pérdida de recursos invertidos en estudiantes que abandonan sin alerta previa. Finalmente, las asignaturas base de la carrera que aportan a la ejecución del presente trabajo son Bases de Datos, Inteligencia Artificial, Ingeniería de Software, Minería de Datos, Sistemas Distribuidos, Desarrollo de Aplicaciones Web, Seguridad de la Información y Estadística, contrastadas contra la malla curricular oficial vigente de la carrera antes de la entrega final.

2. Referencias

Ascoli, B. G., & Choi, J. D. (2025). Advancing conversational Text-to-SQL: Context strategies and model integration with large language models. Future Internet, 17(11), 527. https://doi.org/10.3390/fi17110527

Carballo-Mendívil, B., Arellano-González, A., Ríos-Vázquez, N. J., & Lizardi-Duarte, M. del P. (2025). Predicting student dropout from day one: XGBoost-based early warning system using pre-enrollment data. Applied Sciences, 15(16), 9202. https://doi.org/10.3390/app15169202

Duro, B., Gomes, A., Correia, F. B., Borges, A. R., & Bernardino, J. (2026). Machine learning and deep learning for dropout prediction in higher education: A review. Computers, 15(3), 164. https://doi.org/10.3390/computers15030164

Gutierrez-Pachas, D. A., Garcia-Zanabria, G., Cuadros-Vargas, E., Camara-Chavez, G., & Gomez-Nieto, E. (2023). Supporting decision-making process on higher education dropout by analyzing academic, socioeconomic, and equity factors through machine learning and survival analysis methods in the Latin American context. Education Sciences, 13(2), 154. https://doi.org/10.3390/educsci13020154

Kok, C. L., Ho, C. K., Chen, L., Koh, Y. Y., & Tian, B. (2024). A novel predictive modeling for student attrition utilizing machine learning and sustainable big data analytics. Applied Sciences, 14(21), 9633. https://doi.org/10.3390/app14219633

Komljenovic, J., Sellar, S., & Birch, K. (2024). Turning universities into data-driven organisations: seven dimensions of change. Higher Education, 89, 1369–1386. https://doi.org/10.1007/s10734-024-01277-z

Lepori, B., & Bornmann, L. (2026). Comparing peers with peers in Higher Education Institutions' evaluations: developing good practices to identify similar institutions by subject profile. Research Evaluation, 35. https://doi.org/10.1093/reseval/rvag012

Marcolino, M. R., Porto, T. R., Primo, T. T., Targino, R., Ramos, V., Queiroga, E. M., Munoz, R., & Cechinel, C. (2025). Student dropout prediction through machine learning optimization: Insights from Moodle log data. Scientific Reports, 15(1), 9840. https://doi.org/10.1038/s41598-025-93918-1

Mejía-Peñafiel, E. F., Aguilar-Reyes, J. E., Morocho-Barrionuevo, T. P., & García-Veloz, M. J. (2026). Metodología de implementación de un dashboard en Power BI para el aprendizaje sistémico de estudiantes universitarios. Revista de Ciencias Sociales, 32(1), 208–219. https://produccioncientificaluz.org/index.php/rcs/index

Mohd Talib, N. I., Abd Majid, N. A., & Sahran, S. (2023). Identification of student behavioral patterns in higher education using K-Means clustering and support vector machine. Applied Sciences, 13(5), 3267. https://doi.org/10.3390/app13053267

Núñez-Naranjo, A. F. (2024). Analysis of the determinant factors in university dropout: a case study of Ecuador. Frontiers in Education, 9, 1444534. https://doi.org/10.3389/feduc.2024.1444534

Orrego Granados, D., Ugalde, J., Salas, R., Torres, R., & López-Gonzales, J. L. (2022). Visual-predictive data analysis approach for the academic performance of students from a Peruvian university. Applied Sciences, 12(21), 11251. https://doi.org/10.3390/app122111251

Rabelo, A. M., & Zárate, L. E. (2025). A model for predicting dropout of higher education students. Data Science and Management, 8(1), 72–85. https://doi.org/10.1016/j.dsm.2024.07.001

Sequeira, R., Reis, A., Alves, P., & Branco, F. (2024). Roadmap for implementing business intelligence systems in higher education institutions: Systematic literature review. Information, 15(4), 208. https://doi.org/10.3390/info15040208

Wirth, R., & Hipp, J. (2000). CRISP-DM: Towards a standard process model for data mining. Proceedings of the 4th International Conference on the Practical Application of Knowledge Discovery and Data Mining, 29–39.

6. Anexos

No.	Nombre o Descripción
1	Video de presentación: https://drive.google.com/file/d/18_yiDyvGPhoAgMhu4lMhR_w30cAHkOoj/view?usp=drive_link Carpeta de presentación: https://drive.google.com/drive/folders/160VBr2jUmxQRSzlZE0wZAfUaHr4682xn?usp=sharing
2	Video de Avance 2:
3	Video de Explicación Técnica:

7. Anexo de información académica.

ÁREAS:	Inteligencia Artificial, Minería de datos, Software
TÍTULO DEL TRABAJO	Desarrollo de un modelo predictivo de abandono estudiantil mediante inteligencia de negocios y procesamiento de lenguaje natural
ASIGNATURAS:	Bases de Datos; Inteligencia Artificial; Ingeniería de Software; Minería de Datos; Seguridad de la Información.

Asignaturas	Contenido	Detalle de su aporte al trabajo
Bases de Datos	Proporciona los fundamentos para el diseño, modelado, estructuración y consulta eficiente de datos relacionales y dimensionales.	Sustenta el diseño del esquema estrella (Kimball) integrando tablas relacionales como estudiantes, matrículas, calificaciones, asistencia y factores socioeconómicos en SQL Server para el análisis de deserción.
Inteligencia Artificial	Brinda conceptos y metodologías para el desarrollo de modelos de aprendizaje automático supervisado y no supervisado.	Aporta el marco para el entrenamiento y validación del algoritmo *Random Forest* (predicción de riesgo) y *K-Means* (segmentación), evaluando métricas de desempeño como ROC-AUC.
Ingeniería de Software	Establece las buenas prácticas para la arquitectura de sistemas, diseño de APIs y desarrollo modular de software.	Fundamenta la arquitectura del prototipo integrando el microservicio predictivo en FastAPI, la interfaz interactiva en React y la capa conversacional NL2SQL.
Procesamiento de Lenguaje Natural	Proporciona técnicas para la interpretación y traducción de lenguaje humano a estructuras computacionales.	Permite la implementación del motor NL2SQL para traducir preguntas de los usuarios en lenguaje natural a consultas SQL automáticas sobre el Data Warehouse.
Minería de Datos	Proceso CRISP-DM, ingeniería de características, ETL	Sustenta la metodología de todo el componente predictivo, desde la comprensión de los datos hasta el despliegue por lotes, y el proceso ETL que puebla el almacén dimensional.

Seguridad de la Información	Control de acceso, aislamiento de datos, cuentas de mínimo privilegio	Fundamenta el diseño de la cuenta de solo lectura del motor conversacional y el aislamiento de acceso por institución a nivel del motor de base de datos, que impide el acceso a las tablas operativas.

Innovación	Integra, bajo una misma arquitectura gobernada, un motor de predicción de abandono estudiantil (Random Forest) y de segmentación institucional (K-Means) expuestos simultáneamente mediante un panel visual y un motor conversacional de lenguaje natural a SQL (NL2SQL), no como componentes aislados, sino leyendo la misma fuente de datos gobernada, con aislamiento de acceso por institución verificado a nivel del motor de base de datos, una combinación que la literatura revisada no aborda en un solo sistema.
Producto desarrollado:	El presente trabajo de titulación incluye como producto final un prototipo funcional de software integrado por un Data Warehouse en SQL Server, un motor predictivo basado en Random Forest y K-Means en Python (FastAPI) y un módulo conversacional NL2SQL con interfaz web en React. TUTOR/A ASIGNADO/A: Msc. Peralta Correa Mirella Azucena / Msc. Espinoza Bravo María Gabriela
CONTACTO CON AUTOR/ES:	**Teléfono:** +593 98 602 3149 **Teléfono:** +593 98 597 6227 **E-mail:** malmachi@unemi.edu.ec **E-mail:** vlluilemap@unemi.edu.ec